

УДК 004.93
<https://doi.org/10.32362/2500-316X-2022-10-5-28-37>



НАУЧНАЯ СТАТЬЯ

Разработка нейросетевой модели для анализа пространственных данных

Е.О. Ямашкина¹,
С.А. Ямашкин²,
О.В. Платонова^{1, @},
С.М. Коваленко¹

¹ МИРЭА – Российский технологический университет, Москва, 119454 Россия

² Национальный исследовательский Мордовский государственный университет им. Н.П. Огарёва, Саранск, 430005 Россия

@ Автор для переписки, e-mail: oplatonova@gmail.com

Резюме

Цели. Цели настоящего исследования – разработка и апробация нейросетевой модели для анализа пространственных данных. Преимуществом предложенной модели является наличие большого количества степеней свободы, что позволяет гибко конфигурировать модель, исходя из решаемой проблемы. Данная разработка входит в состав базы знаний репозитория моделей глубокого машинного обучения, включающего подсистему динамической визуализации на основе адаптивных веб-интерфейсов с интерактивной возможностью прямого редактирования архитектуры и топологии нейросетевых моделей.

Методы. Решение проблемы повышения точности анализа и классификации пространственных данных основано на привлечении геосистемного подхода, предполагающего анализ генетической однородности территориально-смежных образований различного масштаба и иерархического уровня. Для апробации предложенной методики применен открытый набор данных EuroSAT, сформированный для обучения и тестирования моделей машинного обучения с целью эффективного решения проблемы классификации систем землепользования и растительного покрова с использованием спутниковых снимков Sentinel-2. Онтологическая модель репозитория, в который входит модель, декомпозируется на домены моделей глубокого машинного обучения, решаемых задач и данных. Это позволяет дать комплексное определение формализуемой области знаний: каждая хранимая нейросетевая модель сопоставлена с набором конкретных задач и наборами данных.

Результаты. Апробация модели для набора EuroSAT, алгоритмически расширенного с позиции геосистемного подхода, дает возможность повысить точность классификации в условиях дефицита обучающих данных в пределах 9%, а также приблизиться к точности глубоких моделей ResNet50 и GoogleNet.

Выводы. Внедрение созданной модели в репозиторий позволит не только сформировать базу знаний моделей для анализа пространственных данных, но и решить проблему подбора эффективных моделей для решения задач в области цифровой экономики.

Ключевые слова: нейронная сеть, глубокое обучение, данные дистанционного зондирования, геосистема, классификация, машинное обучение

• Поступила: 20.12.2021 • Доработана: 11.07.2022 • Принята к опубликованию: 24.08.2022

Для цитирования: Ямашкина Е.О., Ямашкин С.А., Платонова О.В., Коваленко С.М. Разработка нейросетевой модели для анализа пространственных данных. *Russ. Technol. J.* 2022;10(5):28–37. <https://doi.org/10.32362/2500-316X-2022-10-5-28-37>

Прозрачность финансовой деятельности: Авторы не имеют финансовой заинтересованности в представленных материалах или методах.

Авторы заявляют об отсутствии конфликта интересов.

RESEARCH ARTICLE

Development of a neural network model for spatial data analysis

Ekaterina O. Yamashkina ¹,
Stanislav A. Yamashkin ²,
Olga V. Platonova ^{1, @},
Sergey M. Kovalenko ¹

¹ MIREA – Russian Technological University, Moscow, 119454 Russia

² National Research Mordovia State University, Saransk, 430005 Russia

@ Corresponding author, e-mail: oplatonova@gmail.com

Abstract

Objectives. The paper aimed to develop and validate a neural network model for spatial data analysis. The advantage of the proposed model is the presence of a large number of degrees of freedom allowing its flexible configuration depending on the specific problem. This development is part of the knowledge base of a deep machine learning model repository including a dynamic visualization subsystem based on adaptive web interfaces allowing interactive direct editing of the architecture and topology of neural network models.

Methods. The presented solution to the problem of improving the accuracy of spatial data analysis and classification is based on a geosystem approach for analyzing the genetic homogeneity of territorial-adjacent entities of different scales and hierarchies. The publicly available EuroSAT dataset used for initial validation of the proposed methodology is based on Sentinel-2 satellite imagery for training and testing machine learning models aimed at classifying land use/land cover systems. The ontological model of the repository including the developed model is decomposed into domains of deep machine learning models, project tasks and data, thus providing a comprehensive definition of the formalizing area of knowledge. Each stored neural network model is mapped to a set of specific tasks and datasets.

Results. Model validation for the EuroSAT dataset algorithmically extended in terms of the geosystem approach allows classification accuracy to be improved under training data shortage within 9% while maintaining the accuracy of ResNet50 and GoogleNet deep learning models.

Conclusions. The implementation of the developed model into the repository enhances the knowledge base of models for spatial data analysis as well as allowing the selection of efficient models for solving problems in the digital economy.

Keywords: neural network, deep learning, remote sensing data, geosystem, classification, machine learning

• Submitted: 20.12.2021 • Revised: 11.07.2022 • Accepted: 24.08.2022

For citation: Yamashkina E.O., Yamashkin S.A., Platonova O.V., Kovalenko S.M. Development of a neural network model for spatial data analysis. *Russ. Technol. J.* 2022;10(5):28–37. <https://doi.org/10.32362/2500-316X-2022-10-5-28-37>

Financial disclosure: The authors have no a financial or property interest in any material or method mentioned.

The authors declare no conflicts of interest.

ВВЕДЕНИЕ

Развитие технологий машинного обучения, в т.ч. основанных на использовании глубоких нейросетевых моделей, позволяет осуществлять высокоточный автоматизированный мониторинг систем природопользования, анализировать закономерности проявления стихийных процессов и явлений. Актуальной научной проблемой является решение задачи классификации типов систем землепользования и растительного покрова на основе данных дистанционного зондирования высокого разрешения. Для этого применяются методы и алгоритмы глубокого машинного обучения в условиях малого количества размеченных данных посредством привлечения геосистемного подхода, предполагающего анализ генетической однородности территориально-смежных образований различного масштаба и иерархического уровня.

Описанная в данной статье модель геосистемного анализа территории позволяет подойти к решению обозначенной проблемы и характеризуется наличием большого количества степеней свободы. Это позволяет гибко конфигурировать инструмент, исходя из решаемой задачи и анализируемых данных. Предложенная разработка входит в состав базы знаний репозитория моделей глубокого машинного обучения, включающего подсистему динамической визуализации на основе адаптивных веб-интерфейсов с интерактивной возможностью прямого редактирования архитектуры и топологии нейросетевых моделей.

Развертывание репозитория нейросетевых моделей позволяет не только сформировать базу знаний для анализа пространственных данных, но и решить проблему подбора эффективных алгоритмов для решения задач в области цифровой экономики. Онтологическая модель декомпозирована на домены моделей глубокого машинного обучения, решаемых задач и данных. Это позволяет дать комплексное определение формализуемой области знаний: каждая хранимая нейросетевая модель сопоставлена с набором конкретных задач и наборами данных.

МЕТОДОЛОГИЯ И МЕТОДЫ ИССЛЕДОВАНИЯ

Использование глубокого машинного обучения позволяет снизить стоимость проводимых исследований в области анализа пространственных данных за счет возможности точной интерполяции

и экстраполяции измерений. Ключ к решению этих задач следует искать не только в совершенствовании архитектур моделей глубокого машинного обучения, но и в разработке методов и алгоритмов оптимального обогащения обучающих наборов данных [1–3]. Авторами предлагается использование геосистемного подхода, в рамках которого состояние и свойства каждой территориальной единицы определяются особенностями ее взаимодействия с окрестными объектами. В [4] доказано, что ландшафт территории имеет горизонтальную, вертикальную и временную структуры: под вертикальной структурой понимается деление ландшафта на геогоризонты, горизонтальная структура связана с делением ландшафта на фации, а временная связана с динамикой состояний ландшафтов.

На основе данного подхода сформулируем предположение о том, что точность классификации земель на базе дистанционного зондирования Земли можно увеличить, если нейронная сеть будет анализировать не только черты конкретной системы, но и особенности тех участков, с которыми она взаимодействует. С целью проверки этой гипотезы необходимо подготовить для обучения моделей несколько наборов данных [5]: базовых (состоящих из размеченных образцов территорий, зафиксированных при помощи космической съемки) и расширенных (дополненных данными о соседних и вмещающих геосистемах).

Перейдем к описанию методики анализа пространственных данных средствами глубокого машинного обучения и формирования глубокой нейросетевой модели, входящей в состав репозитория, способной эти данные эффективно проанализировать. Обоснованные с позиции системного анализа пользовательского опыта графические веб-интерфейсы репозитория глубоких нейросетевых моделей позволяют осуществлять подбор релевантной модели машинного обучения для решения конкретных задач анализа пространственных данных, получать систематизированную информацию о необходимой глубокой нейросетевой модели.

На рис. 1 представлена онтологическая модель репозитория, декомпозированная на домен моделей глубокого машинного обучения, домен решаемых проектных задач и домен пространственных данных. Это позволяет дать комплексное определение

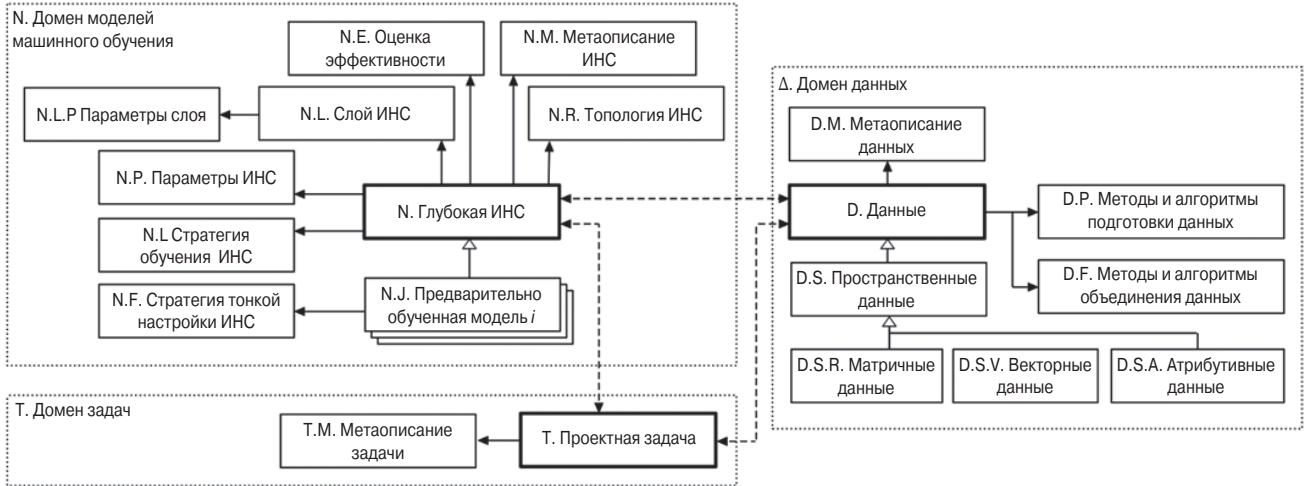


Рис. 1. Модель данных репозитория

формализуемой области знаний: каждая хранимая нейросетевая модель сопоставлена с набором конкретных задач и наборами данных. Организованная таким образом система дает возможность релевантного поиска эффективного архитектурного решения и его тонкой настройки для решения проектных задач посредством графического веб-интерфейса репозитория нейронных сетей.

Для интеграции и использования нейронных сетей предложена схема хранения моделей в виде метаязыка, которая позволяет конвертировать их в представления, используемые фреймворками машинного обучения. С позиции теоретико-множественного подхода набор моделей репозитория $MODELS$ представляет собой универсальное множество, мощность которого определяется числом моделей репозитория:

$$MODELS = \{MODEL_i | 1 \leq i \leq N \wedge i \in \mathbb{Z}\}.$$

Топология нейросетевой модели $MODEL_i$ может быть описана в виде граф-схемы $GRAPH_i$ и структурированного мета-описания $META_i$ (включая кортеж параметров модели $COMPILATION_i$, описывающий методы и алгоритмы оптимизации нейросетевой модели, а также параметры ее функционирования). Элемент $GRAPH_i$ – это ориентированный граф, в котором множество вершин $LAYERS_i$ определяет набор слоев модели, а множество дуг $LINKS_i$ – топологию сети, устанавливая связи между слоями:

$$MODEL_i = \langle META_i, GRAPH_i \rangle = \\ = \langle META_i, \langle LAYERS_i, LINKS_i \rangle \rangle.$$

Ключевым компонентом графовой модели i выступает слой $LAYER_{ij}$, который может быть представлен в виде набора объектов, определяющих архитектуру слоя $TYPE_{layer_{ij}}$, набор интерфейсов $INTERFACES_{ij}$ и аргументов $PROPERTIES_{ij}$:

$$LAYER_{ij} = \langle TYPE_{layer_{ij}}, INTERFACES_{ij}, PROPERTIES_{ij} \rangle.$$

Объект $TYPE_{layer}$ определяет архитектуру слоя и задает особенности обработки данных и настройки гиперпараметров при обучении модели. Параметры интерфейса $INTERFACES_{ij}$ слоя $LAYER_{ij}$ (входов $INPUTS_{ij}$ и выходов $OUTPUTS_{ij}$) определяются кортежем $\langle name, type \rangle$, где $name$ задает название интерфейса, $type$ – размерность и тип данных.

$$INTERFACES_{ij} = \langle INPUTS_{ij}, OUTPUTS_{ij} \rangle = \\ = \langle \{INPUTS_{ij\lambda} | 1 \leq \lambda \leq \Lambda \wedge \lambda \in \mathbb{Z}\}, \\ \{OUTPUTS_{ij\mu} | 1 \leq \mu \leq M \wedge \mu \in \mathbb{Z}\} \rangle.$$

Набор $PROPERTIES_{ij}$ задает гиперпараметры, описывающие особенности функционирования слоя $LAYER_{ij}$. Данный набор именованных аргументов может включать определение алгоритмов инициализации весов, регуляризации, активации.

Для осуществления классификации пространственных данных перейдем к проектированию глубокой нейронной сети $MODEL$, принимающей на вход тензоры данных различного иерархического уровня о классифицируемой территории и вмещающих ее геосистемах. С точки зрения «черного ящика», глубокая модель классификации, основанная на применении геосистемного подхода, представляет собой функциональный элемент, принимающий на вход полученные на основе космической съемки изображения территории и вмещающих ее геосистем, а также синтетических карт [6, 7]. Количество входов $INPUTS$ может варьироваться, исходя из числа уровней геосистемной модели территории. Однако к их росту следует относиться с осторожностью, т.к. это неминуемо повлечет необходимость роста емкости модели. Модель имеет один выход, имеющий форму вектора, каждый i -й элемент которого определяет прогнозируемую вероятность принадлежности

территории i -му классу. Итоговая гипотеза о принадлежности территории определенному классу выдвигается по принципу «победитель получает все», при котором объект относится к классу, для которого модель предсказывает максимальную вероятность. Перейдем к декомпозиции модели.

Структура каждого блока представляет собой цепочку слоев *LAYERS*. Первый слой, осуществляющий операцию глубинной разделимой свертки, позволяет извлечь признаки из исходного изображения и, в отличие от применения обычного сверточного слоя, позволяет сделать модель более компактной и, соответственно, устойчивой к переобучению. Лежащая в основе функционирования слоя операция двухмерной свертки с ядром \mathbf{W} размера K представляет собой линейное преобразование, при котором каждое значение $y_{i,j}$ выходной матрицы \mathbf{Y} рассчитывается на основе значений x исходной матрицы \mathbf{X} согласно следующему выражению:

$$y_{i,j} = \mathbf{W} \cdot \mathbf{X} = \sum_{a=0}^{K-1} \sum_{b=0}^{K-1} W_{a,b} x_{i+a,j+b}.$$

Операция свертки обладает важными свойствами: сохраняет структуру и геометрию входа, характеризуется разреженностью и многократным использованием одних и тех же весов. Операция глубинной разделимой свертки работает не только с пространственными измерениями, но также с измерением глубины, например, каналами изображения, и, в отличие от классической свертки, предполагает использование отдельных сверточных ядер, на основе которых к исходному тензору последовательно применяются две свертки: глубинная и поточечная.

Отметим, что при решении тестовых задач классификации, описанных далее, было проведено сплит-тестирование моделей с классическими сверточными слоями и с глубинной разделимой сверткой, которое подтвердило эффективность использования второго подхода. Следующим слоем блока извлечения признаков, эффективность которого была апробирована экспериментально, стал слой *batch normalization* [8], позволяющий достичь регуляризации и устойчивости модели [9, 10]. Для выполнения операции активации была выбрана функция ReLU^1 [11], осуществляющая преобразование вида $x = \max(0, x)$. Завершает блок извлечения признаков слой субдискретизации, осуществляющий применение операции максимума для уменьшения размера получаемых представлений и имеющий внешние выходы. Эксперименты показали, что применение операции взятия максимума показало

наилучший результат. Отметим, что количество выходных фильтров в свертке и размер ядра свертки предлагается выбирать по принципу минимизации этих значений с сохранением приемлемой точности классификации. С каждым новым шагом, заключающимся в извлечении признаков следующего уровня, рекомендуется увеличение количества выходных фильтров для глубинной разделимой свертки.

Следующим компонентным блоком модели является модуль слияния признаков. Он принимает на вход признаки уровня N , извлеченные из изображения классифицируемой территории и ассоциируемых с ним изображений геосистем. Также модули слияния второго и последующих уровней принимают на вход выходные данные предыдущего модуля слияния. Все входные данные конкатенируются в единый тензор и подвергаются обработке при помощи конвейера извлечения признаков. Он состоит из слоев глубинной разделимой свертки, пакетной нормализации, активации и субдискретизации.

Выход последнего модуля слияния признаков преобразуется в вектор и подается на вход многослойного персептрона. Число плотно связанных слоев многослойного персептрона и их мощность выбираются по принципу минимизации данных параметров при сохранении достаточной точности классификации. Кроме этого, для решения проблемы переобучения рекомендуется применение пакетной нормализации и прореживания к выходам плотно-связанного слоя. Для активации выхода входного и скрытых слоев выбрана функция ReLU , для выходного слоя – Sigmoid [12] при бинарной классификации и Softmax [12] при мультиклассовой.

При обучении классификатора в качестве оптимизатора используется алгоритм RMSProp^2 , основанный на методе стохастического градиентного спуска, а в качестве функции потерь – перекрестная энтропия. На тонкую настройку модели оказывает влияние особенности конкретной решаемой задачи классификации [13]. Перейдем к апробации модели.

АПРОБАЦИЯ МОДЕЛИ

Для первичной апробации предложенной методики применен открытый набор данных *EuroSAT* [14], сформированный для обучения и тестирования моделей машинного обучения с целью эффективного решения проблемы классификации

¹ <https://pytorch.org/docs/stable/generated/torch.nn.ReLU.html>, дата обращения 27.07.2022. [<https://pytorch.org/docs/stable/generated/torch.nn.ReLU.html>. Accessed July 27, 2022.]

² Hinton G., Srivastava N., Swersky K. *Neural networks for machine learning. Lecture 6a. Overview of mini-batch gradient descent*. URL: <http://www.cs.toronto.edu/~hinton/coursera/lecture6/lec6.pdf>, дата обращения 27.07.2022. [Hinton G., Srivastava N., Swersky K. *Neural networks for machine learning. Lecture 6a. Overview of mini-batch gradient descent*. URL: <http://www.cs.toronto.edu/~hinton/coursera/lecture6/lec6.pdf>. Accessed July 27, 2022.]

Таблица. Точность классификации различных моделей для набора данных EuroSAT

Метод	Число модулей	Набор данных	Диапазон тестирования								
			10/90	20/80	30/70	40/60	50/50	60/40	70/30	80/20	90/10
CNN (2layers)	422 378	EuroSAT	75.88	79.84	81.29	83.04	84.48	85.77	87.24	87.96	88.66
ResNet-50	25 636 712	EuroSAT	75.06	88.53	93.75	94.01	94.45	95.26	95.32	96.43	96.37
GoogleNet	6 797 700	EuroSAT	77.37	90.97	90.57	91.62	94.96	95.54	95.70	96.02	96.17
Разработанная модель	1 324 526	Расширенный EuroSAT	86.23	91.52	93.98	94.11	94.29	94.35	94.41	94.65	95.30

систем землепользования и растительного покрова с использованием спутниковых снимков Sentinel-2³ [15]. Набор данных равномерно размечен на 10 классов (annual crop – однолетние культуры; forest – леса; herbaceous vegetation – травянистая растительность; highway – шоссе; industrial – промышленные объекты; pasture – пастбища; permanent crop – многолетние культуры; residential – жилые кварталы; river – реки; water – открытые водоемы) и состоит из 27 000 изображений, содержащих информацию об участках земель, распределенных по территории Европейского Союза, в 13 спектральных диапазонах. Каждый элемент набора данных имеет размер 64 × 64 пикселя с пространственным разрешением 10 м на пиксель, а также характеризуется географической привязкой.

Приведем характеристики сравнения точности классификации различных моделей для набора данных EuroSAT [16], проводимой на основе различных соотношений тренировочных и тестовых выборок. Нейросетевая модель ResNet-50 [17] показывает точность 96.43% (для разделения обучающих и проверочных данных в соотношении 80 к 20) и 75.06% (при соотношении 10 к 90). Небольшая сверточная сеть в два слоя достигает точности в 87.96% (разделение 80 к 20) и 75.88% (разделение 10 к 90). Отметим также, что модели глубокого машинного обучения на основе сверточных слоев показали преимущественно большую точность, чем машины опорных векторов.

Таким образом, современные глубокие сверточные сети показывают превосходную точность классификации космических снимков при относительно большом размере обучающей выборки набора данных EuroSAT. Однако в условиях нехватки обучающих данных представленные подходы начинают значительно терять в точности. Проблема повышения точности методов и алгоритмов анализа пространственных данных в условиях их дефицита является актуальной и открытой.

Процесс получения дополнительных данных потенциально подлежит полной автоматизации:

обладая сведениями о географических координатах (широте и долготе) классифицируемого участка, можно сделать запрос к API провайдера пространственных данных на получение фрагмента космического снимка территории, включающего эти координаты и характеризующегося необходимым масштабом и разрешением. Таким образом, мы получаем возможность алгоритмического расширения набора обучающих данных за счет импорта фрагментов космической съемки, характеризующих геосистемы более высокого иерархического уровня и вмещающие классифицируемый участок.

В настоящее время пространственные данные открыто предоставляются множеством провайдеров через Интернет, некоторые из которых предлагают для быстрого получения удобные прикладные программные интерфейсы (API) [18, 19]. Тот факт, что эти данные обладают низким временным разрешением (часто мы не имеем возможности и близко выбрать конкретную дату космической съемки), обуславливает их низкую стоимость. Одновременно с этим, они не перестают быть информативным источником сведений о вмещающих геосистемах различного иерархического уровня. Авторами статьи использована платформа API Mapbox⁴ для автоматизированной аугментации исходного набора данных космическими снимками различного масштаба.

Сравнительные значения точности предложенной модели и CNN (2 layers) [12], ResNet-50, GoogleNet [20] представлены в таблице. При выделении тестовых данных из набора EuroSAT в соотношении 40% и ниже предложенная в статье модель показывает наилучший результат, причем относительная эффективность растет с уменьшением обучающей выборки до 10% (86.23% против 77.37% у второго результата (GoogleNet)). С ростом размера обучающих данных модель начинает уступать глубоким моделям ResNet-50 и GoogleNet, однако этот разрыв укладывается в диапазон 2%.

Разработанная модель позволила получить такие результаты благодаря анализу расширенного с позиции геосистемного подхода набора EuroSAT

³ <https://sentinel.esa.int/web/sentinel/missions/sentinel-2>, дата обращения 27.07.2022. [<https://sentinel.esa.int/web/sentinel/missions/sentinel-2>. Accessed July 27, 2022.]

⁴ <https://docs.mapbox.com/api/overview/>, дата обращения 27.07.2022. [<https://docs.mapbox.com/api/overview/>. Accessed July 27, 2022.]




Рис. 2. Матрица ошибок

(в то время как модели ResNet-50 и GoogleNet обучались и анализировали исходный набор данных EuroSAT. Разница в условиях проведения эксперимента нивелировалась низкой стоимостью и быстротой полностью автоматизированного процесса расширения обучающего набора, а также более низкой емкостью модели: 1.3 млн единиц против 6.8 млн у GoogleNet и 25.6 млн у ResNet-50. Таким образом, получение преимущества в обучении модели в условиях дефицита данных обусловлено малозатратным автоматизированным расширением набора на основе геосистемного подхода и созданием эффективной модели для его анализа.

Представляет интерес анализ процесса обучения модели. Так как обучение нейронных сетей – это вероятностный процесс, была проведена серия из 10 экспериментов, по результатам которой построена зависимость математического ожидания и стандартного отклонения точности классификации на проверочных данных от эпохи обучения. Модель на ранних стадиях процесса обучения показывает низкую точность классификации расширенного набора, которая начинает расти практически с нулевого значения. Сверточная нейронная сеть в два слоя и модель ResNet50 с первой эпохи достигают точности выше 40%. Однако после десятой эпохи

обучения созданная модель опережает другие модели, достигая ожидаемой точности в 86%. Также отметим малое среднее квадратическое отклонение от математического ожидания зависимости, характерное при обучении на малом наборе данных. Это говорит о большей устойчивости процесса обучения модели и высокой способности к правильному обобщению информации об анализируемых признаках.

Разберем случаи, когда разработанная модель показала более низкую точность. Матрица ошибок представлена на рис. 2. Низкие значения попаданий для классов highway, industrial, water возникают из-за того, что учет изображений вмещающих геосистем при классификации неминуемо приводит к росту анализируемых данных, для анализа которых может потребоваться большая емкость модели. Кроме того, дополнительные изображения в ряде случаев могут ввести модель классификации в заблуждение: определено, с точки зрения алгоритма гораздо проще классифицировать одно однородное изображение водной поверхности, нежели изображение, дополненное несколькими фрагментами более мелкого масштаба, включающими прибрежные территории.

Таким образом, расширение набора EuroSAT с позиции геосистемного подхода и разработка модели позволили повысить точность классификации

в условиях дефицита обучающих данных (разделении обучающего набора на обучающий и тестовый в соотношении от 10/90 до 40/60) и показать результаты, которые превышают значения точности моделей глубокого машинного обучения при классификации набора EuroSAT.

ЗАКЛЮЧЕНИЕ

Разработанная нейросетевая модель, входящая в состав базы знаний репозитория моделей глубокого машинного обучения, позволяет решить проблему повышения точности анализа и классификации пространственных данных посредством привлечения геосистемного подхода, предполагающего анализ генетической однородности территориально-смежных образований различного масштаба и иерархического уровня. Внедрение в репозиторий позволит не только сформировать базу знаний моделей для анализа пространственных данных, но и решить проблему подбора эффективных моделей для решения задач в области цифровой экономики. Преимуществом предложенной модели является наличие высокого количества степеней свободы, что позволяет гибко конфигурировать модель, исходя из решаемой проблемы.

Апробация модели для набора EuroSAT, алгоритмически расширенного с позиции геосистемного подхода, показала возможность повышения точности классификации в условиях дефицита обучающих данных в пределах 9%, а также приближения к точности глубоких моделей ResNet50 и GoogleNet. После десятой эпохи обучения созданная модель опережает другие модели, достигая ожидаемой точности в 86%.

СПИСОК ЛИТЕРАТУРЫ

1. Saleh H., Alexandrov D., Dzhonov A. Uberisation business model based on blockchain for implementation decentralized application for lease/rent lodging. In: Rocha Á., Serhini M. (Eds.). *Information Systems and Technologies to Support Learning (EMENA-ISTL 2018)*. Smart Innovation, Systems and Technologies. *International Conference Europe Middle East & North Africa*. Springer, Cham. 2018;111:225–232. https://doi.org/10.1007/978-3-030-03577-8_26
2. Сигов А.С., Цветков В.Я., Рогов И.Е. Методы оценки сложности тестирования в сфере образования. *Russ. Technol. J.* 2021;9(6):64–72. <https://doi.org/10.32362/2500-316X-2021-9-6-64-72>
3. Liu Y., Sangineto E., Bi W., Sebe N., Lepri B., Nadai M. Efficient training of visual transformers with small datasets. *Advances in Neural Information Processing Systems*. 2021;34:23818–23830. URL: <https://arxiv.org/pdf/2106.03746.pdf>

БЛАГОДАРНОСТИ

Работа выполнена при финансовой поддержке гранта Президента Российской Федерации (грант № МК-199.2021.1.6).

ACKNOWLEDGMENTS

The study was supported by the grant from the President of the Russian Federation, project No. MK-199.2021.1.6).

Вклад авторов

Е.О. Ямашкина – разработка и описание методологии исследования, проведение экспериментов, оптимизация модели.

С.А. Ямашкин – постановка задачи и обоснование концепции исследования, проектирование и разработка нейросетевой модели.

О.В. Платонова – анализ отечественного и зарубежного опыта в области интерпретации пространственных данных, работа с материалом, редактирование и подготовка рукописи.

С.М. Коваленко – планирование эксперимента, интерпретация и обобщение результатов исследования.

Authors' contributions

E.O. Yamashkina – development and description of the research methodology, conducting experiments, and model optimization.

S.A. Yamashkin – statement of the problem and justification of the research concept, design and development of a neural network model.

O.V. Platonova – analysis of domestic and foreign experience in the field of interpretation of spatial data, work with the material, editing and preparation of the manuscript.

S.M. Kovalenko – planning of the experiment, interpretation and generalization of the results of the study.

REFERENCES

1. Saleh H., Alexandrov D., Dzhonov A. Uberisation business model based on blockchain for implementation decentralized application for lease/rent lodging. In: Rocha Á., Serhini M. (Eds.). *Information Systems and Technologies to Support Learning (EMENA-ISTL 2018)*. Smart Innovation, Systems and Technologies. *International Conference Europe Middle East & North Africa*. Springer, Cham. 2018;111:225–232. https://doi.org/10.1007/978-3-030-03577-8_26
2. Sigov A.S., Tsvetkov V.Ya., Rogov I.E. Methods for assessing testing difficulty in education sphere. *Russ. Technol. J.* 2021;9(6):64–72 (in Russ.). <https://doi.org/10.32362/2500-316X-2021-9-6-64-72>
3. Liu Y., Sangineto E., Bi W., Sebe N., Lepri B., Nadai M. Efficient training of visual transformers with small datasets. *Advances in Neural Information Processing Systems*. 2021;34:23818–23830. Available from URL: <https://arxiv.org/pdf/2106.03746.pdf>

4. Занозин В.В., Карабаева А.З., Конеева А.В., Макеева Е.В., Молокова В.Г. Особенности горизонтальной структуры центральной части ландшафта дельты Волги. *Географические науки и образование: сб. трудов XI Всероссийской научно-практической конференции*. 2018. С. 161–163.
5. Yamashkina E.O., Kovalenko S.M., Platonova O.V. Development of repository of deep neural networks for the analysis of geospatial data. *IOP Conf. Ser.: Mater. Sci. Eng.* 2021;1047(1):012124. <https://doi.org/10.1088/1757-899X/1047/1/012124>
6. Weiss M., Jacob F., Duveiller G. Remote sensing for agricultural applications: A meta-review. *Remote Sens. Environ.* 2020;236(5):111402. <https://doi.org/10.1016/j.rse.2019.111402>
7. Ямашкин С.А., Ямашкин А.А. Повышение эффективности процесса интерпретации данных дистанционного зондирования Земли за счет анализа дескрипторов окрестности. *Инженерные технологии и системы*. 2018;28(3):352–365. <https://doi.org/10.15507/0236-2910.028.201803.352-365>
8. Ioffe S., Szegedy Ch. *Batch Normalization: accelerating deep network training by reducing internal covariate shift*. Preprint. March 2, 2015. URL: <https://arxiv.org/pdf/1502.03167.pdf>
9. Yao Z., Cao Y., Zheng S., Huang G., Lin S. Cross-iteration Batch Normalization. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2021:12331–12340. <https://doi.org/10.1109/CVPR46437.2021.01215>
10. Jung W., Jung D., Kim B., Lee S., Rhee W., Ahn J.H. Restructuring Batch Normalization to accelerate CNN training. In: *Proceedings of Machine Learning and Systems*. 2019;1:14–26. URL: <https://mlsys.org/Conferences/2019/doc/2019/18.pdf>
11. Chen Y., Dai X., Liu M., Chen D., Yuan L., Liu Z. Dynamic ReLU. In: Vedaldi A., Bischof H., Brox T., Frahm J.M. (Eds.). *Computer Vision – ECCV 2020. ECCV 2020. Lecture Notes in Computer Science*. Cham: Springer; 2020. V. 12364. P. 351–367. https://doi.org/10.1007/978-3-030-58529-7_21
12. Gu J., et al. Recent advances in convolutional neural networks. *Pattern Recognition*. 2018;77:354–377. <https://doi.org/10.1016/j.patcog.2017.10.013>
13. Kozaev A., Saleh H., Alexandrov D. Simulation of emergency situations on main gas pipeline with MATLAB Simulink. In: *2019 Actual Problems of Systems and Software Engineering (APSSE)*. IEEE. 2019:63–68. <https://doi.org/10.1109/APSSE47353.2019.00015>
14. Helber P., Bischke B., Dengel A., Borth D. Introducing EuroSAT: A novel dataset and deep learning benchmark for land use and land cover classification. In: *IEEE International Symposium on Geoscience and Remote Sensing (IGARSS)*. 2018: 204–207. <https://doi.org/10.1109/IGARSS.2018.8519248>
15. Phiri D., Simwanda M., Salekin S., Nyirenda V.R., Murayama Y., Ranagalage M. Sentinel-2 data for land cover/use mapping: a review. *Remote Sens.* 2020;12(14):2291. <https://doi.org/10.3390/rs12142291>
16. Helber P., Bischke B., Dengel A., Borth D. EuroSAT: A novel dataset and deep learning benchmark for land use and land cover classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*. 2019;12(7): 2217–2226. <https://doi.org/10.1109/JSTARS.2019.2918242>
4. Zanozin V.V., Karabaeva A.Z., Koneeva A.V., Makeeva E.V., Molokova V.G. Features of the horizontal structure of the central part of the Volga delta landscape. In: *Geographic Sciences and Education: Proceedings of the XI All-Russian Conf.* 2018. P. 161–163 (in Russ.).
5. Yamashkina E.O., Kovalenko S.M., Platonova O.V. Development of repository of deep neural networks for the analysis of geospatial data. *IOP Conf. Ser.: Mater. Sci. Eng.* 2021;1047(1):012124. <https://doi.org/10.1088/1757-899X/1047/1/012124>
6. Weiss M., Jacob F., Duveiller G. Remote sensing for agricultural applications: A meta-review. *Remote Sens. Environ.* 2020;236(5):111402. <https://doi.org/10.1016/j.rse.2019.111402>
7. Yamashkin S.A., Yamashkin A.A. Improving the efficiency of remote sensing data interpretation by analyzing neighborhood descriptors. *Inzhenernye tekhnologii i sistemy = Engineering Technologies and Systems (Vestnik Mordovskogo universiteta = Mordovia University Bulletin)*. 2018; 28(3):352–365 (in Russ.). <https://doi.org/10.15507/0236-2910.028.201803.352-365>
8. Ioffe S., Szegedy Ch. *Batch Normalization: accelerating deep network training by reducing internal covariate shift*. Preprint. March 2, 2015. Available from URL: <https://arxiv.org/abs/1502.03167>
9. Yao Z., Cao Y., Zheng S., Huang G., Lin S. Cross-iteration Batch Normalization. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2021:12331–12340. <https://doi.org/10.1109/CVPR46437.2021.01215>
10. Jung W., Jung D., Kim B., Lee S., Rhee W., Ahn J.H. Restructuring Batch Normalization to accelerate CNN training. In: *Proceedings of Machine Learning and Systems*. 2019;1:14–26. Available from URL: <https://mlsys.org/Conferences/2019/doc/2019/18.pdf>
11. Chen Y., Dai X., Liu M., Chen D., Yuan L., Liu Z. Dynamic ReLU. In: Vedaldi A., Bischof H., Brox T., Frahm J.M. (Eds.). *Computer Vision – ECCV 2020. ECCV 2020. Lecture Notes in Computer Science*. Cham: Springer; 2020. V. 12364. P. 351–367. https://doi.org/10.1007/978-3-030-58529-7_21
12. Gu J., et al. Recent advances in convolutional neural networks. *Pattern Recognition*. 2018;77:354–377. <https://doi.org/10.1016/j.patcog.2017.10.013>
13. Kozaev A., Saleh H., Alexandrov D. Simulation of emergency situations on main gas pipeline with MATLAB Simulink. In: *2019 Actual Problems of Systems and Software Engineering (APSSE)*. IEEE. 2019:63–68. <https://doi.org/10.1109/APSSE47353.2019.00015>
14. Helber P., Bischke B., Dengel A., Borth D. Introducing EuroSAT: A novel dataset and deep learning benchmark for land use and land cover classification. In: *IEEE International Symposium on Geoscience and Remote Sensing (IGARSS)*. 2018: 204–207. <https://doi.org/10.1109/IGARSS.2018.8519248>
15. Phiri D., Simwanda M., Salekin S., Nyirenda V.R., Murayama Y., Ranagalage M. Sentinel-2 data for land cover/use mapping: a review. *Remote Sens.* 2020;12(14):2291. <https://doi.org/10.3390/rs12142291>
16. Helber P., Bischke B., Dengel A., Borth D. EuroSAT: A novel dataset and deep learning benchmark for land use and land cover classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*. 2019;12(7): 2217–2226. <https://doi.org/10.1109/JSTARS.2019.2918242>

17. Szegedy Ch., Ioffe S., Vanhoucke V., Alemi A. Inception-v4, Inception-ResNet and the impact of residual connections on learning. In: *Thirty-First AAAI Conference on Artificial Intelligence*. 2017;31(1). <https://doi.org/10.1609/aaai.v31i1.11231>
18. Yamashkin S.A., Radovanovic M.M., Yamashkin A.A., Barmin A.N., Zanozin V.V., Petrovic M.D. Problems of designing geoportal interfaces. *GeoJournal of Tourism and Geosites*. 2019;24(1):88–101. <https://doi.org/10.30892/gtg.24108-345>
19. Soni A., Ranga V. API features individualizing of web services: REST and SOAP. *Int. J. Innovative Technol. Exploring Eng.* 2019;8(9S):664–671. <https://doi.org/10.35940/ijitee.I1107.0789S19>
20. Szegedy Ch., et al. Going deeper with convolutions. In: *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2015;1–9. <https://doi.org/10.1109/CVPR.2015.7298594>
17. Szegedy Ch., Ioffe S., Vanhoucke V., Alemi A. Inception-v4, Inception-ResNet and the impact of residual connections on learning. In: *Thirty-First AAAI Conference on Artificial Intelligence*. 2017;31(1). <https://doi.org/10.1609/aaai.v31i1.11231>
18. Yamashkin S.A., Radovanovic M.M., Yamashkin A.A., Barmin A.N., Zanozin V.V., Petrovic M.D. Problems of designing geoportal interfaces. *GeoJournal of Tourism and Geosites*. 2019;24(1):88–101. <https://doi.org/10.30892/gtg.24108-345>
19. Soni A., Ranga V. API features individualizing of web services: REST and SOAP. *Int. J. Innovative Technol. Exploring Eng.* 2019;8(9S):664–671. <https://doi.org/10.35940/ijitee.I1107.0789S19>
20. Szegedy Ch., et al. Going deeper with convolutions. In: *2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2015;1–9. <https://doi.org/10.1109/CVPR.2015.7298594>

Об авторах

Ямашкина Екатерина Олеговна, аспирант, кафедра вычислительной техники Института информационных технологий ФГБОУ ВО «МИРЭА – Российский технологический университет» (119454, Россия, Москва, пр-т Вернадского, д. 78). E-mail: eoladanova@yandex.ru. Scopus Author ID 57222118879, SPIN-код РИНЦ 9940-1751, <https://orcid.org/0000-0002-8086-7717>

Ямашкин Станислав Анатольевич, к.т.н., доцент, кафедра автоматизированных систем обработки информации и управления Института электроники и светотехники Национального исследовательского Мордовского государственного университета им. Н.П. Огарёва (430005, Россия, Саранск, ул. Большевикская, д. 68). E-mail: yamashkinsa@mail.ru. ResearcherID N-2939-2018, Scopus Author ID 9133286400, SPIN-код РИНЦ 5569-7314, <https://orcid.org/0000-0002-7574-0981>

Платонова Ольга Владимировна, к.т.н., доцент, заведующий кафедрой вычислительной техники Института информационных технологий ФГБОУ ВО «МИРЭА – Российский технологический университет» (119454, Россия, Москва, пр-т Вернадского, д. 78). E-mail: oplatonova@gmail.com. Scopus Author ID 57222119478, SPIN-код РИНЦ 4680-5904

Коваленко Сергей Михайлович, к.т.н., профессор, кафедра вычислительной техники Института информационных технологий ФГБОУ ВО «МИРЭА – Российский технологический университет» (119454, Россия, Москва, пр-т Вернадского, д. 78). E-mail: kovalenko@mirea.ru. Scopus Author ID 57222117274, SPIN-код РИНЦ 7308-8250

About the authors

Ekaterina O. Yamashkina, Postgraduate Student, Computer Technology Department, Institute of Information Technologies, MIREA – Russian Technological University (78, Vernadskogo pr., Moscow, 119454 Russia). E-mail: eoladanova@yandex.ru. Scopus Author ID 57222118879, RSCI SPIN-code 9940-1751

Stanislav A. Yamashkin, Cand. Sci. (Eng.), Associate Professor, Department of Automated Information Processing and Management Systems, Institute of Electronics and Lighting Engineering, Ogarev Mordovia State University (68, Bolshevistskaya ul., Saransk, 430005 Russia). E-mail: yamashkinsa@mail.ru. ResearcherID N-2939-2018, Scopus Author ID 9133286400, RSCI SPIN-code 5569-7314, <https://orcid.org/0000-0002-7574-0981>

Olga V. Platonova, Cand. Sci. (Eng.), Associated Professor, Head of the Computer Technology Department, Institute of Information Technologies, MIREA – Russian Technological University (78, Vernadskogo pr., Moscow, 119454 Russia). E-mail: oplatonova@gmail.com. Scopus Author ID 57222119478, RSCI SPIN-code 4680-5904

Sergey M. Kovalenko, Cand. Sci. (Eng.), Professor, Computer Technology Department, Institute of Information Technologies, MIREA – Russian Technological University (78, Vernadskogo pr., Moscow, 119454 Russia). E-mail: kovalenko@mirea.ru. Scopus Author ID 57222117274, RSCI SPIN-code 7308-8250